

Universidade da Coruña

FACULTAD DE INGENIERIA INFORMÁTICA

DETECCIÓN DE VOLCANES EN LA
SUPERFICIE DE VENUS MEDIANTE
MACHINE LEARNING

Memoria

Autores:

Brezmes Villaraviz, Elena. Canedo Fernández, David. Blanco Amoedo,
Rodrigo, Castro Vázquez, Javier.

2023

Índice

| | |
|--|----------|
| 1. Introducción | 3 |
| 1.1. Definiciones | 3 |
| 2. Descripción del Problema | 3 |
| 2.1. Restricciones | 3 |
| 2.2. Descripción de la BD | 4 |
| 2.3. Métricas | 4 |
| 3. Análisis Bibliográfico | 4 |
| 4. Desarrollo | 5 |
| 4.1. Primera Aproximación | 5 |
| 4.1.1. Descripción | 5 |
| 4.1.2. Resultados | 6 |
| 4.1.3. Problemas Encontrados | 7 |
| 5. Conclusiones | 7 |
| 6. Trabajo Futuro | 7 |
| 7. Bibliografía | 8 |

Índice de figuras

| | | |
|----|---|---|
| 1. | Gráf. de dispersión de los patrones obtenidos con 2 características | 6 |
| 2. | Tabla de resultados del modelo “RNA” de la aproximación 1 | 6 |

1. Introducción

Detectar todas las apariciones de un objeto de interés en un conjunto de imágenes es un problema que puede surgir en dominios como la vigilancia militar, el diagnóstico o la geología planetaria. Dada la prevalencia de este problema y el hecho de que las continuas mejoras en la tecnología de adquisición y almacenamiento de imágenes producirán colecciones de imágenes cada vez más grandes, hacen que exista una clara necesidad de algoritmos y herramientas que puedan ser utilizados para localizar automáticamente objetos de interés dentro de dichos conjuntos de datos.

El presente proyecto tiene como objetivo la detección de volcanes en la superficie de Venus utilizando técnicas de aprendizaje automático. La detección de volcanes es una tarea importante en la exploración planetaria, ya que ayuda a entender la actividad volcánica pasada y presente de un planeta y puede contribuir a la identificación de posibles zonas habitables. Aunque ya existen métodos para la detección de volcanes en Venus, estos presentan limitaciones que pueden afectar su precisión y efectividad.

Este proyecto se divide en los siguientes apartados: análisis bibliográfico, desarrollo y conclusiones. En el análisis bibliográfico se revisará la literatura científica existente sobre la detección de volcanes en Venus y se compararán los métodos actuales con nuestra propuesta. En el desarrollo se describirán en detalle las técnicas utilizadas en la propuesta y se presentarán los resultados obtenidos. Finalmente, en las conclusiones se resumirán las principales conclusiones del proyecto y se propondrán posibles direcciones para futuros trabajos.

En resumen, se pretende crear una nueva metodología para la detección de volcanes en la superficie de Venus (o cualquier otro planeta) que combina diferentes técnicas de aprendizaje automático. Se espera que los resultados obtenidos contribuyan a mejorar la precisión y efectividad en la detección de volcanes y puedan ser útiles para futuras misiones de exploración planetaria.

1.1. Definiciones

- K-NN: K-nearest neighbors
- RRNNAA: Redes Neuronales Artificiales
- UCI: University of California Irvine
- SAR: Synthetic Aperture Radar
- BD: Base de Datos
- NASA: National Aeronautics and Space Administration
- ASCII: American Standard Code for Information Interchange
- \bar{x} : Media
- σ : Desviación Típica
- SVM: Support Vector Machine

2. Descripción del Problema

Nuestro proyecto consiste en la elaboración de software que sea capaz de identificar, en la superficie del planeta Venus, qué formaciones rocosas son volcanes. Para ello, hacemos uso de redes neuronales, máquinas de soporte vectorial y k-NN en cada aproximación, observando así con cual se obtiene un mejor resultado.

2.1. Restricciones

Las imágenes de las que disponemos cuentan con poca resolución, lo cual, si bien ayuda a que la ejecución del código sea mas rápida, entorpece el reconocimiento de patrones y características. Debido a las condiciones de las tomas de imagen de la muestra, estas no van a ser perfectamente perpendiculares, esto significa que cuanto más nos alejemos del centro de la imagen, más deformadas estarán las estructuras.

Por otra parte, al convertirlas a un formato visualizable se ha perdido el color, característica que se podría haber utilizado para afinar el análisis de características y patrones. Además, es complicado distinguir en las imágenes los accidentes geográficos que buscamos, ya que la superficie está llena de lo que entendemos que son líneas que marcan la cima de dunas creadas por los vientos que asolan el planeta y cambian la forma de estas cada día.

Cabe destacar también, que Venus es un planeta que carece de una atmósfera lo suficientemente densa como para reducir el tamaño de los cuerpos que impactan contra su superficie. Dicho impacto genera cráteres circulares que sumados a la baja resolución de las imágenes, pueden llevar a confusión y dificultan en gran medida el reconocimiento de lo que nos interesa, los volcanes.

2.2. Descripción de la BD

La base de datos que utilizamos no es propia, la hemos obtenido de la página web UCI [1]. Esta base de datos nos proporciona 134 imágenes de 1024 x 1024 píxeles de la superficie del planeta Venus, archivos de "GroundTruth", que especifican las ubicaciones de los volcanes dentro de las imágenes y etiquetas que facilitan alguna medida de incertidumbre subjetiva (1 = definitivamente un volcán; 2 = probablemente; 3 = posiblemente; 4 = solo se ve un pozo). Se nos proporcionan también archivos ASCII simples (.lxyr) que contienen, separados por espacios, la etiqueta, la ubicación x del centro, la ubicación y del centro y el radio de cada volcán.

Todos estos datos fueron recopilados por la nave espacial Magallán durante un período de aproximadamente 4 años, de 1990 a 1994. Probablemente por eso, las imágenes obtenidas son de baja calidad. Esto se podría solucionar aplicando técnicas de preprocesado de imágenes pero se ha obviado al considerar que escapa de las competencias de la asignatura.

2.3. Métricas

Respecto a la métrica seleccionada, siendo un modelo de detección de volcanes en imágenes de la superficie de Venus, creemos que sería más importante priorizar la sensibilidad. La razón es que el objetivo principal de nuestro modelo es detectar la mayor cantidad posible de volcanes en la imagen, incluso si se cometen algunos errores al clasificar otros objetos como volcanes, ya que su identificación es de suma importancia en la investigación y el conocimiento de la geología del planeta.

3. Análisis Bibliográfico

El uso de herramientas de aprendizaje automático para la extracción de información a partir del ingente y creciente agregado de datos que tenemos en la actualidad, es algo cada vez más habitual y sensato. Estas herramientas aportan en muchos casos, una asistencia "real", eficiente y competitiva para aplicaciones tan heterogéneas como la minería de datos o el machine learning y distintos tipos de cuestiones relacionadas con la astronomía, [8], donde además se justifica que la selección del algoritmo o modelo y el tener en cuenta el dominio y el problema astronómico en cuestión produce mejores resultados que el uso de modelos siguiendo una filosofía de "caja negra", donde solo se puede confiar "ciegamente" en que el sistema de buenos resultados. Otro de los ámbitos de utilidad de estas herramientas lo vemos en la detección de enfermedades cutáneas mediante deep o machine learning [9], en el que se plantea, entre otros 2 casos clínicos, la necesidad de una herramienta altamente sensible y eficiente para ayudar a discernir a médicos generales en casos en los que errar a la hora de dar un diagnóstico traería consigo unas consecuencias graves para el paciente.

Como trabajo "referente" podemos citar un trabajo para la detección de volcanes en la superficie de Venus, [6], trayendo como resultado un software eficaz, JARTool, software que según ellos y demostrándolo con la detección de volcanes en un conjunto reducido de las imágenes producidas por la sonda Magallán, extraerá información para la que ha sido entrenado, permitiendo que el análisis por parte de expertos humanos se vuelva abordable de manera práctica.

Gracias a la información e imágenes extraídas en trabajos como el anterior y en trabajos como el del telescopio Arecibo, utilizado para producir mapas de radar de Venus que fueron pioneros en nuestra comprensión de los accidentes geográficos de la superficies y los procesos geológicos del planeta [3], se escribieron artículos en revistas científicas que hemos utilizado como fuente de información para esta práctica. Por una parte, algunos de estos artículos nos hablan sobre cómo tanto la misión Magallán

como el telescopio Arecibo, han hecho que empiece a conocerse más el planeta Venus y que cada vez estemos obteniendo más información sobre dicho planeta [2]; se nos comenta también, que la sonda Magallán fotografió varias veces algunas áreas volcánicas y examinando dichas áreas se identificó que algunos respiraderos volcánicos van cambiando de forma con el paso del tiempo, [5].

Por otra parte, y en menor cantidad, disponemos de artículos que tratan sobre el desarrollo de herramientas útiles para analizar la superficie de Venus y su rugosidad, [7], a partir de los datos adquiridos por medio del satélite Magallán de la NASA y derivando las mediciones de la superficie de Venus utilizando el SAR estéreo de Magallán; y, la creación de algoritmos como YOLO (You-Only-Look-Once), basados en redes neuronales, y su utilización junto a técnicas de aumento deterministas para la detección y clasificación de volcanes, [4]. Este último artículo, lo hemos utilizado como “comparador” ya que nuestro trabajo también se basa en una serie de algoritmos basados en máquinas de soporte vectorial y k-NN, además de en redes neuronales, para la posterior identificación y clasificación de volcanes en la superficie de Venus.

4. Desarrollo

El desarrollo de esta investigación se llevará a cabo en cuatro aproximaciones distintas. Cada aproximación, a su vez, utilizará cuatro métodos distintos de Machine Learning: K-NN, RNA, SVM y árboles de decisión.

4.1. Primera Aproximación

En esta primera aproximación nuestro trabajo se ha centrado sobre todo en la obtención de datos así como en la revisión de trabajos anteriores relacionados con el tema, dejando en un segundo lugar la precisión obtenida por el sistema, que se irá mejorando en las futuras aproximaciones.

4.1.1. Descripción

Las tareas realizadas en esta aproximación podrían dividirse en las siguientes:

- **Preprocesado de datos:** se empieza por extraer muestras del dataset. Concretamente de aquellos elementos de cada imagen que se sabe seguro que se trata de un volcán y cuales no basándonos en el fichero .lxyr que acompaña a cada imagen. De este conseguimos para cada punto de interés, sus coordenadas X,Y dentro de la función y el radio en píxeles. Para cada uno de estos se coge la submatriz pertinente de la imagen a la que referencia el fichero y se crea un recorte con dicho punto que se guarda en la carpeta “miss” en el caso de los puntos marcados como “1” (Seguro que no son volcanes) y en “hit” en el caso contrario, marcados como “4” en el primer elemento del fichero.
- **Extracción de características:** como primera aproximación, acordamos empezar por aquellas más sencillas, por tanto, hemos elegido la media y la desviación típica, ya que por la naturaleza de nuestros datos, ambas nos aportarán información útil para discernir si el elemento a clasificar es un volcán o no. En especial la desviación, ya que si es muy alta, quiere decir que el gradiente de grises es muy agresivo, lo cual es usual en el tipo de accidente geográfico buscado. Es importante mencionar que no se realiza una normalización de los datos ni antes ni después, dado que debido a los valores escogidos, si se ejecutase, se suavizarían las disparidades entre los números, lo cual dificultaría la correcta identificación de elementos, porque precisamente aquellos que son cráteres tienen un gradiente de gris muy agresivo, lo cual es una característica clave por lo que acabamos de mencionar. A continuación, una vez calculados los resultados, estos se guardan en una matriz, donde cada fila será un recorte constará de 3 columnas, que a su vez serán “media—desviación—volcán”, donde el último valor identificará si ese recorte era o no un volcán. Este parámetro viene definido por los datos de los ficheros .lxyr, en el cual, para cada fila, el 1º valor ya indica si es (4) o seguro que no (1).
- **Entrenamiento y obtención de resultados:** apoyándonos en el código desarrollado para las prácticas y sobre todo, la librería SciKit-learn, cargamos los vectores que obtuvimos en el punto anterior y, ejecutamos la primera opción, RRNNAA. Debido a dificultades técnicas dentro de la función confusionMatrix, no conseguimos probarlo con el resto de posibilidades.

4.1.2. Resultados

En la siguiente figura mostramos la división de los patrones de entrenamiento, validación y test. Los patrones están coloreados según su clase, siendo de color rojo aquellos que se corresponden con la imagen de un volcán y de color azul los que no.




Figura 1: Gráf. de dispersión de los patrones obtenidos con 2 características

A continuación, presentamos la tabla de resultados del modelo de RRNNAA. Los términos son:

- Arquitectura :
Número de neuronas que hay entre la capa de entrada (tantas neuronas como características) y la capa de salida (varía con las distintas clases en la que se pueden clasificar los patrones), es decir, las neuronas que hay en las capas ocultas, descartando las previamente citadas.
- Media de precisión del test en validación cruzada "k-fold":
Se hace la media de la precisión en los distintos modelos que se obtienen utilizando un "10-fold".
- Desviación típica del test :
Se hace la desviación típica de los distintos modelos, de forma similar a la media anterior.
- Media de Sensibilidad de test :
Se calcula la media de sensibilidad de entre todos los modelos.
- Desviación típica de Sensibilidad de test :
Se calcula la desviación típica de sensibilidad de entre todos los modelos.

| Arquitectura | \bar{x} | σ | \bar{x} Sensibilidad | σ Sensibilidad |
|--------------|-----------|----------|------------------------|-----------------------|
| 3 | 80,05 | 3,62 | 0,0 | 0,0 |
| 1 | 80,06 | 6,15 | 0,0 | 0,0 |
| 2 | 80,05 | 3,79 | 0,0 | 0,0 |
| 1, 1 | 80,06 | 3,73 | 0,0 | 0,0 |
| 1, 2 | 80,06 | 4,34 | 0,0 | 0,0 |
| 3, 4 | 80,06 | 4,34 | 0,0 | 0,0 |
| 2, 3 | 80,06 | 4,98 | 0,0 | 0,0 |
| 5, 5 | 80,06 | 3,27 | 0,0 | 0,0 |

Figura 2: Tabla de resultados del modelo "RNA" de la aproximación 1

4.1.3. Problemas Encontrados

Al encontrarnos en la primera aproximación, hemos cometido un error de organización, centrando la mayoría de nuestros esfuerzos en la parte de investigación de trabajos previos y la búsqueda de posibles características para extraer de las imágenes, y descuidando, por tanto, la parte de la implementación. Como resultado, hemos descubierto errores de último momento que no hemos podido subsanar.

Por todo esto, la implementación no funciona correctamente, impidiéndonos así la realización de análisis de resultados.

Estos errores serán corregidos (actualizando por tanto las conclusiones) junto a la segunda aproximación.

5. Conclusiones

6. Trabajo Futuro

El trabajo realizado se irá mejorando en las siguientes aproximaciones. Concretamente, se mejorarán los siguientes aspectos:

- Extracción más completa de características, entre ellas podríamos destacar:
 - Histograma de la imagen. Un histograma muestra una representación gráfica de la luz en una imagen. El eje horizontal corresponde a la variedad de tonos (y va de negros a blancos), mientras que el vertical indica la cantidad de píxeles de cada tono. Por tanto un histograma con valores muy altos en la parte central representaría una imagen con muchos píxeles con tonos medios, mientras que un histograma muy disperso pertenecería a una imagen con un gran contraste, lo que podría indicar la presencia de un volcán.
 - Transformada de Fourier. Esta se utiliza para convertir señales (incluidas imágenes) en el dominio del espacio a su representación en el dominio de la frecuencia. Si aplicamos la Transformada de Fourier a una imagen y vemos que hay una gran cantidad de energía en una cierta frecuencia, esto puede indicar la presencia de un patrón o estructura específica en la imagen, en nuestro caso, un cráter volcánico.
 - Simetría de la imagen. Los cráteres volcánicos son depresiones circulares, es decir tienen simetría, por lo que esta característica puede ser adecuada para detectar presencia de un volcán en una imagen.
- Afinar los parámetros de entrenamiento para obtener los mejores resultados posibles.
- Desarrollo del análisis y clasificación de elementos de entrada más allá de si es volcán o no. Podríamos tener 3 clases, dividiendo entre si es volcán, no es volcán y podría o no ser un volcán.
- Preprocesado de las imágenes utilizadas. Se podrían aplicar técnicas de visión artificial de forma que se aumentase el contraste de la imagen para facilitar la detección de los volcanes.

7. Bibliografía

Referencias

- [1] *Base de datos con imágenes de la superficie de Venus*. URL: <https://archive.ics.uci.edu/ml/datasets/volcanoes+on+venus+-+jartool+experiment>.
- [2] D. L. Bindshadler. *Magellan: A new view of Venus' geology and geophysics*. Electronic Article. Ene. de 1995. DOI: [10.1029/95RG00281](https://doi.org/10.1029/95RG00281). URL: <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/95RG00281>.
- [3] Bruce A. Campbell y Donald B. Campbell. *Arecibo Radar Maps of Venus from 1988 to 2020*. Electronic Article. Abr. de 2022. DOI: [10.3847/PSJ/ac4f43](https://doi.org/10.3847/PSJ/ac4f43). URL: <https://iopscience.iop.org/article/10.3847/PSJ/ac4f43>.
- [4] Daniel Duranovic et al. *Localization and Classification of Venusian Volcanoes Using Image Detection Algorithms*. Electronic Article. 20/01/2023 de 2023. DOI: [10.3390/s23031224](https://doi.org/10.3390/s23031224). URL: <https://www.mdpi.com/1424-8220/23/3/1224>.
- [5] Robert R. Herrick y S. Hensley. *Surface changes observed on a Venusian volcano during the Magellan mission*. Electronic Article. 15/03/2023 de 2023. DOI: [10.1126/science.abm7735](https://doi.org/10.1126/science.abm7735). URL: <https://www.science.org/doi/10.1126/science.abm7735>.
- [6] ET AL. M. BURL. *Learning to Recognize Volcanoes on Venus*. Electronic Article. Ene. de February 1998. DOI: [10.1023/A:1007400206189](https://doi.org/10.1023/A:1007400206189). URL: <https://link.springer.com/article/10.1023/A:1007400206189>.
- [7] K.E Maurice et al. *Venus surface roughness and Magellan stereo data*. Electronic Article. 14/09/1994 de 2022. DOI: [1.26:196821](https://doi.org/1.26:196821). URL: <https://ntrs.nasa.gov/citations/19950005291>.
- [8] ET AL. Nicholas M. Ball. *Data Mining and Machine Learning in Astronomy*. Electronic Article. Ene. de 2009. DOI: [10.1142/S0218271810017160](https://doi.org/10.1142/S0218271810017160). URL: <https://www.semanticscholar.org/paper/Data-Mining-and-Machine-Learning-in-Astronomy-Ball-Astrophysics/6241276a3074f73c1ce9b9ce4ac69f748732aecd>.
- [9] ET AL. Yicen Yan. *Artificial Intelligence in Skin Diseases: Fulfilling its Potentials to Meet the Real Needs in Dermatology Practice*. Electronic Article. Ene. de 2022. DOI: [10.34133/2022/9791467](https://doi.org/10.34133/2022/9791467). URL: <https://spj.science.org/doi/10.34133/2022/9791467>.